

発生頻度の少ないコーディング規約違反データ統合による検出精度向上への試み

亀岡 令[†]
和歌山大学[†]

伊原彰紀[‡]
和歌山大学[‡]

南雄太[§]
和歌山大学[§]

大森 楓木[¶]
和歌山大学[¶]

1 はじめに

開発者は保守管理の観点から、コーディング規約を遵守することによって可読性の高いコードを書くことが求められる。コーディング規約とは、ソースコードを記述する際に、保守性や可読性を高めるためにインデントや括弧などの記法を定めたものである。コーディング規約の例として、Python の PEP8 や Java の Code Conventions for the Java Programming Language などがある。ただし、開発者が自らこれらの規約に違反しているコード断片を特定し、修正を行うことは時間的コストを要するため、静的解析ツールツールが用いられる。

静的解析ツールは、ツールによって定義されたルールによって該当するすべてのコーディング規約違反を検出することができる。これによってプログラム中のコーディング規約違反が大量に発見されることが多い。だが、開発者がここで発見された規約違反コードをすべて修正することは無い。従来研究では、機械学習を用いて静的解析ツールによって発見された規約違反が修正されたかを学習し、優先して修正すべき規約違反の検出を行っている [1]。しかし、規約違反の種類ごとの分布には偏りがあるため、違反頻度の低い規約は機械学習において、予測精

度は学習データセットの大きさ、正例不例の割合などに依存する問題が起こる。

本研究では、連合学習を用いて学習することで、予測精度の向上させることを目的とする。連合学習は、学習データから得られたモデルに加えて、別の学習データから得られたモデルも利用してモデルを構築するため、それぞれの学習データセットの特徴を考慮することができる。具体的には、プログラムの編集履歴を特徴量とし、違反が修正された編集の特徴をもとにし、連合学習によって構築されたモデルを利用することで、規約違反が修正させるかを予測する。

2 分析

2.1 データセット

本研究では、GitHub から Python で実装されており Pylint を用いて開発されている transitions, schematics, schema_salad, python-bugzilla, python-cloudant, pycard, pynput, OWSLib, howdoi, hickle の 10 リポジトリを対象とする。これらのリポジトリからそれぞれ 1,000 日間のコミットを分析対象とする。

2.2 分析手法

規約違反が修正されるかの予測には、GitHub で管理された編集履歴から、変更行数や複雑度などソースコードや編集についての 43 個の特徴量を抽出し、FedAvg アルゴリズムを用いた連合学習を行う [2]。目的変数は、あるコミットにおいて規約違反が修正されたか、されなかったかの二値とし、説明変数には規約違反の種

Toward improving detection accuracy by integrating occasional coding convention violations datasets

[†] Ryo Kameoka, Wakayama University

[‡] Akinori Ihara, Wakayama University

[§] Yuta Minami, Wakayama University

[¶] Fuki Omori, Wakayama University




図1: 連合学習のアルゴリズム

表1: 分析結果

	適合率	再現率	F1 値
連合学習モデル	0.03	0.52	0.06
深層学習モデル	0.03	0.32	0.05

類やソースコードの複雑度などの 44 個のパラメータを用いる。学習データとテストデータは、コミットの古い順から 7 割を学習データとし、残り 3 割を予測データとすることで、時系列を考慮した予測を行う。

FedAvg を用いた連合学習の概要は、図 1 のように個別の深層学習によって得られたモデルを集約し平均を取り、再度学習する際に出力されたモデルと、先ほど得られたモデルとの平均を取る。このようにモデルの構築、得られたモデルの集約、再度学習を繰り返すことで、より精度の高いモデルを得る手法である。実装には、オープンソースフレームワークの OpenFL を用いる。

今回使用した深層学習のレイヤーは 3 層で、1,2 層目は ReLU 層であり、3 層目にシグモイド関数を用いた出力層となっている。最適化アルゴリズムには Adam を利用し、学習率は 0.01 に設定した。

2.3 結果

分析の結果から

3 おわりに

本研究では、静的解析ツールによって検出された規約違反が予測地点において修正されるかを、連合学習によって精度向上を試みた。今後の方針として、データセットの拡張、違反頻度の低い規約違反への重み付けなどを用いて予測精度の高いモデルの構築を目指す。

謝辞

~~~~~

## 参考文献

- [1]
- [2] Brendan McMahan, Eider Moore, Daniel Ramage, Seth Hampson, Blaise Aguera y Arcas: Communication-Efficient Learning of Deep Networks from Decentralized Data: Proceedings of the 20th International Conference on Artificial Intelligence and Statistics (PMLR), No54, pp. 1273-1282, (2017)